

專案作業一

決策樹分類器

M11323035 周冠諺

M11423034 賴冠綸

M11423038 張勗恩

M11423055 陳昱廷

指導教授：許中川 博士

Advisor: Chung-Chian Hsu, Ph. D.

中華民國 114 年 10 月

摘要

本研究旨在以實證方式比較四種決策樹演算法——ID3、C4.5、C5.0 與 CART——於 UCI Adult Dataset (Census Income Dataset) 上之分類效能，以探討不同演算法在預測個體年收入是否超過 50,000 美元時的準確性與泛化能力。研究動機源於決策樹模型在資料探勘領域的高可解釋性與規則透明特性，為機器學習中具代表性的分類方法。研究方法使用 Python 之 scikit-learn 與 id3-estimator 實作 ID3、C4.5 與 CART，並結合 R 語言之 C5.0 模型輸出結果進行跨平台效能比較。實驗資料經前處理（包括類別標籤化、缺失值處理、特徵合併與冗餘欄位刪除）後，以統一的訓練與測試集評估各模型表現。結果顯示，ID3 模型測試準確率為 0.8428，C4.5 為 0.8453，CART 在未剪枝時雖達 0.9749 的訓練準確率但測試準確率僅 0.8143，顯示過度擬合；而 C5.0 模型整合資訊增益率與提升式學習策略後，測試準確率達 0.8670，為四者之最。再進一步對 CART 應用最小成本複雜度剪枝 (Minimal Cost-Complexity Pruning) 後，在 $ccp_alpha = 0.00015$ 時，測試準確率提升至 0.8581，接近 C5.0 模型之水準，證實剪枝能有效提升模型泛化能力並降低過擬合風險。綜合而言，C5.0 於準確率與穩定性方面表現最佳，C4.5 與經剪枝優化之 CART 亦具實用價值，本研究結果可作為決策樹模型選擇與優化之參考依據。

關鍵詞： ID3、C4.5、C5.0、CART

一、緒論

1.1 動機

在資料探勘與機器學習領域中，演算法的比較與應用是理解模型特性的重要途徑。決策樹演算法因其可解釋性高、邏輯結構清晰而被廣泛採用，常作為分類任務的入門與進階研究範例。本研究選用 Adult Dataset (Census Income Dataset)，該資料集包含來自美國人口普查的真實資料，具有龐大的樣本數與多元的屬性型態，能有效模擬現實資料探勘中的挑戰情境，適合作為決策樹演算法實作與比較的教材[1]。

1.2 目的

本研究旨在運用 Python 及其資料探勘套件 scikit-learn，實作多種決策樹演算法 (ID3、C4.5、C5.0 與 CART)，以分析不同模型於 Adult Dataset 上預測年收入 ($>50K$ 與 $\leq 50K$) 時的分類效能。透過調整參數與應用剪枝 (post-pruning) 方法，進一步探討模型在避免過度擬合及提升泛化能力上的表現，並藉此累積在機器學習模型建構、優化與評估方面的實務經驗。

二、方法

本研究採用四種決策樹分類演算法 (ID3、CART、C4.5、C5.0) 對 Adult 資料集進行預測分析。本節說明本研究的程式架構與執行方法。

2.1 程式架構與功能概覽

本研究的程式實作分為三個關鍵環節，涵蓋了資料處理、特定模型訓練以及結果整合與比較。其使用的檔案名稱和主要功能如表 1 所示。

表 1、程式檔案與功能對應表

程式檔案	主要功能
------	------

PreprocessDataToCsv.ipynb	資料前處理：生成所有模型所需的 CSV 資料。
run_c50_script.ipynb	C5.0 模型訓練：使用 R 語言中的 C50 套件訓練，並輸出預測結果與評估指標檔案。(ipynb 檔)
CART Decision Tree.ipynb	Python 模型訓練與比較：訓練 ID3、CART、C4.5 模型，讀取 C5.0 結果，進行所有模型結果比較及 成本複雜度剪枝 (CCP) 分析。
run_c50_script.R	C5.0 模型訓練：使用 R 語言中的 C50 套件訓練，並輸出預測結果與評估指標檔案。(R 語言檔)

2.2 程式執行方法

(1)資料前處理：首先執行 PreprocessDataToCsv.ipynb。此步驟完成資料的載入、清理、特徵工程與編碼，生成所有後續模型所需的 CSV 資料檔案。

(2) C5.0 模型訓練：接著執行 C5.0 模型以生成預測結果。此步驟有兩種執行方式：

- 選項一(Jupyter)：在 Jupyter 環境中執行 run_c50_script.ipynb，此需確保環境中已安裝並配置 IRkernel，以便執行 R 語言程式碼。
 - 選項二(R 語言)：透過 R 語言環境直接執行 run_c50_script.R 腳本。
- 無論採用何種方式，皆需系統安裝 R 語言及 C50 等必要套件，最終輸出 C5.0 的預測結果 (c50_result.csv) 和評估指標 (c50_metrics.csv)。

(3)Python 分析：最後執行 CART Decision Tree.ipynb。此檔案會訓練 ID3、CART、C4.5 三個模型，並讀取第二步輸出的 C5.0 結果，以完成所有模型的性能比較、詳細分類報告以及 CART 的成本複雜度剪枝分析。

三、實驗

3.1 資料集

資料名稱：Adult 資料集

機器學習任務(Associate Tasks): 分類(Classification)

總資料筆數：48842

訓練資料筆數(adult.data)：32561

測試資料筆數(adult.test)：16281

資料集資訊：資料擷取工作由 Barry Becker 從 1994 年人口普查資料庫中完成。

提取條件如下：((AAGE>16) && (AGI>100) && (AFNLWGT>1)&& (HRSWK>0)) 預測任務是確定一個人的年收入是否超過 50,000 美元。

表 2、Adult 資料集欄位介紹

欄位	欄位名稱	角色	資料型別	資料描述	缺失值
1	age	Feature	Integer	continuous	no
2	workclass	Feature	Categorical	Private, Self-emp-not-inc, Self-emp-inc, Federal-gov, Local-gov, State-gov, Without-pay, Never-worked	yes
3	fnlwgt	Feature	Integer	continuous	no
4	education	Feature	Categorical	Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, 12th, Masters, 1st-4th, 10th, Doctorate, 5th-6th, Preschool	no
5	education-num	Feature	Integer	continuous	no
6	marital-status	Feature	Categorical	Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse	no
7	occupation	Feature	Categorical	Tech-support, Craft-repair, Other-service, Sales, Exec-managerial, Prof-specialty, Handlers-cleaners, Machine-op-	yes

				inspct, Adm-clerical, Farming-fishing, Transport-moving, Priv-house-serv, Protective-serv, Armed-Forces	
8	relationship	Feature	Categorical	Wife, Own-child, Husband, Not-in-family, Other-relative, Unmarried	no
9	race	Feature	Categorical	White, Asian-Pac-Islander, Amer-Indian-Eskimo, Other, Black	no
10	sex	Feature	Binary	Female, Male	no
11	capital-gain	Feature	Integer	continuous	no
12	capital-loss	Feature	Integer	continuous	no
13	hours-per-week	Feature	Integer	continuous	no
14	native-country	Feature	Categorical	United-States, Cambodia, England, Puerto-Rico, Canada, Germany, Outlying-US(Guam-USVI-etc), India, Japan, Greece, South, China, Cuba, Iran, Honduras, Philippines, Italy, Poland, Jamaica, Vietnam, Mexico, Portugal, Ireland, France, Dominican-Republic, Laos, Ecuador, Taiwan, Haiti, Columbia, Hungary, Guatemala, Nicaragua, Scotland, Thailand, Yugoslavia, El-Salvador, Trinidad&Tobago, Peru, Hong, Holand-Netherlands	yes
15	income	Target	Binary	<=50K, >50K	no

3.2 前置處理

為了使 Adult 之資料集能更適用於決策樹模型的訓練，並提升模型的效率與穩健

性，本實驗事先對資料集執行了以下一系列的前處理步驟。

(1) 缺失值處理

經檢視，資料集中的 `workclass`、`occupation`，及 `native-country` 三個特徵中存在以 '?' 標記的缺失值。由於資料集筆數夠多，本實驗採取刪除法，將有缺失值之資料刪除。經處理後，分別對訓練集移除了 2,399 筆(約佔 7.36%)，對測試集移除了 1,222 筆(約佔 7.50%)。

(2) 特徵移除

為降低模型複雜度並移除潛在雜訊，本實驗移除了以下兩類特徵。

(i) 冗餘特徵

對於 `education` 屬性(教育程度)與 `education-num` 屬性(受教育年限)本實驗發現其中存在對應關係，選擇其中一個特徵便能代表其教育程度。因此為了簡化特徵之複雜度，移除 `education` 欄位，保留了數值型別的 `education-num`。

(ii) 無關特徵

根據 Adult 資料集的敘述，`fnlwgt` 屬性代表人口普查的權重，此權重反映的是該實例在總人口中的代表性，而非個體本身的特徵。因此其與個體收入的預測任務無直接關聯，並可能使模型學到一個錯誤的規則成為雜訊，因此本實驗將其從特徵集中移除。

(3) 特徵合併

在 `native-country` 之特徵，其包含高達 41 個國家類別。但觀察各類別之佔比可發現，`United-States` 佔據了絕大多數樣本，對訓練集及測試集之占比分別高達 89.58% 及 91.56%。因此為了避免決策樹產生過多分支導致 overfitting，本

實驗採用特徵合併，將非 United-States 之特徵合併為一個新的類別 'Other'。

(4) 新特徵創建

(i) 淨資本 (Capital):

創建一個新的 capital 特徵，其定義為 capital-gain (資本收益) 減去 capital-loss (資本損失)，以整合淨資本變化。

(ii) 工時分組 (Hours Group)

將連續型的 hours-per-week (每週工時) 特徵離散化 (Discretization) 為三個類別：'less_than_40' (小於 40 小時)、'exactly_40' (等於 40 小時) 與 'more_than_40' (大於 40 小時)。

(iii) 年齡分組 (Age Group)

將 age (年齡) 特徵離散化為三個類別：'young' (小於 30 歲)、'middle' (30 至 49 歲) 與 'senior' (50 歲及以上)。

(5) 目標變數轉換:

目標變數 income 為二元類別。因此本實驗將其進行標籤編碼，將目標變數 $\leq 50K$ 編碼為 0，將 $> 50K$ 編碼為 1。

經上述之資料前處理後，資料集的變化如表 3 所示。

表 3、資料集前後對比表

資料集	訓練集資料筆數	測試集資料筆數
資料處理前	32561	16280
資料處理後	30162	15059

3.3 實驗設計

本研究的實驗設計旨在評估與分析 ID3、C4.5、C5.0、CART 等決策樹演算法在分類任務上的績效，並深入探討剪枝機制對模型複雜度與泛化能力的影響，首先探討各決策樹演算法之比較。

(1)ID3 (Iterative Dichotomiser 3):

採用 id3-estimator 套件中的 Id3Estimator，其餘參數採預設值。此演算法使用「熵」(Entropy)作為資訊增益(Information Gain)的計算標準。

(2)CART (Classification and Regression Trees):

採用 sklearn.tree 套件中的 DecisionTreeClassifier，根據 criterion、random_state 等參數進行設定，如表 4 所示。

表 4、 CART 參數說明

criterion	設為 gini，指定使用「Gini 不純度」作為分割的品質衡量標準，這是 CART 演算法的標準配置。
random_state	設為 42，固定隨機種子，確保實驗可以被完整重現。

(3)C4.5:

採用 sklearn.tree 套件中的 DecisionTreeClassifier，根據 criterion、random_state、min_samples_leaf 等參數進行設定，如表 5 所示。

表 5、 C4.5 參數說明

criterion	設為 entropy，指定使用「熵」作為分割標準，以模擬 C4.5 使用資訊增益率 (Gain Ratio) 的邏輯。
random_state	設為 42，固定隨機種子，確保實驗可以被完整重現。
min_samples_leaf	設為 10，這是一種「預剪枝」(Pre-pruning) 的策略。它要求一個節點分裂後的子節點（葉節點）必須

	至少包含 10 個樣本，防止模型過度複雜和過擬合。
--	---------------------------

再來則深入探討「最小成本複雜度剪枝」(Minimal Cost-Complexity Pruning,) 對決策樹模型之影響，本實驗選擇 CART 演算法進行比較。

- (1) 首先會在訓練集上使用 `cost_complexity_pruning_path` 函數，計算出一個基準 CART 模型所有可能的有效 `ccp_alpha` (成本複雜度參數) 值。
- (2) 針對上一步生成的 `ccp_alphas` 序列 (排除了非正值與效能最差的樹根節點)，本實驗為每一個 `ccp_alpha` 值重新訓練 CART 模型。
- (3) 針對上一步對 `ccp_alpha` 值訓練之 CART 模型，本實驗繪製了 `ccp_alpha` 值與對應的訓練集、測試集準確率關係圖 (Accuracy vs. Alpha)，以視覺化方式辨識 Overfitting、Underfitting 及最佳績效的區間。
- (4) 根據關係圖，本實驗手動選取了三個具代表性的 `ccp_alpha` 值 0.0000、0.01750、0.00015 進行深入分析，並將這三棵樹的結構進行視覺化。

3.4 實驗結果

本章節旨在呈現 3.3 節所述實驗設計之結果。本實驗首先評估了 ID3、CART，以及 C4.5 三種演算法在訓練集及測試集之 Accuracy 表現。

表 6、決策樹演算法之 Accuracy 比較表

方法	訓練集 Accuracy	測試集 Accuracy
ID3	0.8967	0.8421
CART	0.9749	0.8159
C4.5	0.8829	0.8458
C5.0	0.8725	0.8647

如表 6 所示，CART 演算法在允許完全生長的情況下，出現了 Overfitting 的現象。這可由其極高的訓練集準確率(0.9749)與相對低的測試集準確率(0.8159)之間的巨大差異得到證實。相較之下，採用了預剪枝策略 (`min_samples_leaf=10`) 的 C4.5 模型，其訓練集準確率 (0.8829) 與測試集準確率 (0.8458) 較為接近，避免了

Overfitting。

為了更詳細探討各演算法之差異，本實驗進一步展示了各演算法在測試集上的詳細績效指標。

表 7、決策樹演算法之績效比較表

方法	Accuracy	Precision	Recall	F1-score
ID3	0.8421	0.8358	0.8421	0.8374
CART	0.8159	0.8145	0.8159	0.8151
C4.5	0.8458	0.8393	0.8458	0.8405
C5.0	0.8647	0.8616	0.8647	0.8627

根據表 7 之結果，C5.0 之演算法在 Accuracy、Precision、Recall，及 F1-score 等數據上皆贏得皆贏得其他演算法，取得最佳績效。

下一部分，本實驗旨在探討 ccp_alpha 參數對各演算法模型準確率與複雜度的影響。由於從決策樹演算法之 Accuracy 比較表可發現，CART 演算法存在 Overfitting 的現象，因此本實驗選擇 Cart 演算法進行後剪枝(post-pruning) 技術之實驗。首先計算了完整的剪枝路徑，根據程式，產生了 2001 個 ccp_alpha 可能之值。接著，針對每個 alpha 分別訓練一個模型，得出以下之結果。




圖 1、測試集準確率關係圖 (Accuracy vs. Alpha)

由圖 1 所示，可發現訓練集(藍線)準確率隨著 α 的增加而呈現遞減，而測試集(橘線)準確率則隨著 α 的增加而上升，這表示輕微的剪枝下可以提升了模型的泛化能力。而測試集準確率在 α 值約 0.00015 處達到峰值，之後測試集準確率開始下降，表明模型開始因過度剪枝而過度簡化，逐步進入 Underfitting 狀態。本實驗也發現在 α 接近 0 之區域，訓練集與測試集準確率之間存在巨大差異，再次驗證了 3.4 節中觀察到的 Overfitting 現象。最後根據不同 ccp_alpha 參數，本實驗彙總了這三種參數設定下的模型評估結果，結果如表 8。

表 8、 ccp_alpha 參數的模型效能與複雜度比較表

參數設定	ccp_alpha	樹高	總節點數	訓練集準確率	測試集準確率
1.	0.0000	46	10719	0.9749	0.8159
2.	0.00015	20	187	0.8676	0.8582
3.	0.0175	2	5	0.8150	0.8153

綜合表 8 所示，本實驗可以得出剪枝對於 Cart 模型的影響。

- (1) $ccp_alpha=0.0000$ ：此模型即為未剪枝之 CART 演算法，它擁有最深的樹高 46 和最多的節點 (10719)，導致了高達 16%訓練集與測試集之準確率差異
- (2) $ccp_alpha=0.00015$ ：引入一個極小的 ccp_alpha 值後，模型複雜度顯著降低，樹高減少至 20，節點數大幅下降至 187 個。最重要的是，測試集準確率達到了本次研究的最高值 0.8582，且與訓練集準確率 0.8676 的差距大幅縮小。這證實了 ccp_alpha 成功地移除了無助於泛化的樹分支，找到了最佳的訓練集、測試集之平衡點。
- (3) $ccp_alpha=0.0175$ ：在提高 α 值到一定程度後，模型會過度簡化，樹高只有 2，總節點數也大幅下降到 5。雖然訓練集和測試集準確率幾乎一致，但兩者的準確率均顯著低於最佳模型，表明此模型已處於 Underfitting 之狀態。

最後，本實驗以視覺化的方式呈現各 Cart 樹枝結構圖，為了圖表的可觀性，結構圖只顯示前四層。

1. (Overfitting) (Alpha=0.0, Depths=46, Nodes=10775)




圖 2、樹 1(Alpha=0.0000)

2. (Underfitting) (Alpha=0.0175, Depths=2, Nodes=5)




圖 3、樹 2(Alpha=0.0175)

3. (The best alpha) (Alpha=0.00015, Depths=20, Nodes=187)




圖 4、樹 3(Alpha=0.00015)

由各 Cart 樹之結構圖可以發現，圖 3 所示之樹 2 雖然效能不佳，但其極度簡潔的結構提供了最強的可解釋性。而圖 4 的樹 3 則在保持高準確率的同時，提供了一個相較於樹更簡潔的決策模型。

四、結論

本研究比較多種決策樹演算法在 Adult 資料集上的分類效能，並深入探討剪枝技術對於模型績效之影響。實驗結果指出，未經剪枝的 CART 模型存在 Overfitting，其在訓練集上高達 97.49% 的準確率與在測試集上 81.59% 的表現形成巨大落差，C4.5 模型的結果亦表明，min_samples_leaf 等預剪枝策略同樣是抑制過擬合的可行方法。而研究的核心發現，是成功地透過最小成本複雜度剪枝(CCP)技術顯著優化了 CART 模型，證明其不僅是防止過擬合的手段，更是提升模型泛化能力的關鍵策略。本實驗透過引入一個 ccp_alpha 參數(0.00015)，不僅將 Cart 模型的測試集準確率從 81.59% 提升至 85.82%，更最佳化模型總節點數，從 10,719 個急劇減少至 187 個，凸顯剪枝在決策樹應用的必要性，但若過度調高 ccp_alpha 參數則可能導致 Underfitting。

參考文獻

- [1] Barry Becker and Ronny Kohavi. 1996. *Adult (or "Census Income") Data Set*. UCI Machine Learning Repository. <https://doi.org/10.24432/C5XW20>. Retrieved October 6, 2025 from <https://archive.ics.uci.edu/dataset/2/adult>
- [2] Scikit-learn developers. (n.d.). 1.10. Decision Trees. Scikit-Learn. <https://scikit-learn.org/stable/modules/tree.html>
- [3] scikit-learn developers. (n.d.). Post Pruning Decision Trees with Cost Complexity Pruning. Scikit-Learn https://scikit-learn.org/stable/auto_examples/tree/plot_cost_complexity_pruning.html#sphx-glr-auto-examples-tree-plot-cost-complexity-pruning-py
- [4] Yylee12. (2022). Day 25. 決策樹(剪枝)、隨機森林(超參數選擇)、重要變數 [PYTHON] (補充二). IThome. <https://ithelp.ithome.com.tw/m/articles/10305134>
- [5] overfitting. (2018, March 8). Income Prediction on UCI Adult Dataset. Kaggle. <https://www.kaggle.com/code/overload10/income-prediction-on-uci-adult-dataset>
- [6] python software foundation. (2017, May 19). Decision-Tree-Id3 0.1.2. Python Package Index. <https://pypi.org/project/decision-tree-id3/>
- [7] 悟乙己. (2015, August 13). 决策树之 ID3、C4.5、C5.0 等五大算法及 python 实现. CSDN. https://blog.csdn.net/sinat_26917383/article/details/47617801